

TALLER DE CLASIFICACIÓN CON ÁRBOLES DE DECISIÓN

Inteligencia Artificial

Camilo Andrés Díaz García

Universidad Sergio Arboleda
Facultad de Sistemas e Ingeniería
Bogotá D.C., 2026

Contenido

1 Introducción **2**

2 Formulación del problema **2**

2.1 (1a) Elementos del problema 2

2.2 (1b) Vocabulario del árbol en este caso 3

2.3 (1c) Campo posterior a la clasificación y disponibilidad del precio 3

3 Selección de la raíz con el índice Gini **4**

3.1 Fórmulas y convenciones 4

3.2 (2a) Impureza de la raíz 4

3.3 (2b) Comparación de las dos preguntas candidatas 4

3.4 (2c) Elección de la raíz 7

4 Construcción e interpretación del árbol **7**

4.1 (3a) División adicional del hijo impuro 7

4.2 (3b) Árbol resultante 9

4.3 (3c) Reglas por hoja 11

4.4 (3c) Clasificación de los casos nuevos 11

4.5 Discusión sobre los casos nuevos y la exactitud en los datos de ajuste . . . 12

5 Evaluación de las predicciones **12**

5.1 (4a) Métricas e interpretación 13

5.2 (4b) Significado de los dos errores 13

5.3 (4c) Modelo que siempre predice la clase mayoritaria 14

6 Implementación y generalización en Python **15**

6.1 Parte A (5A): verificación del cálculo manual 15

6.2 Parte B (5B): experimento con Iris 16

7 Conclusiones **22**

1 Introducción

Este informe resuelve el taller de clasificación con árboles de decisión del curso de Inteligencia Artificial. El trabajo parte de una tabla sintética de 12 diamantes, sobre la cual se formula el problema, se elige la raíz con el índice Gini, se construye un árbol a mano y se evalúan sus predicciones con métricas de clasificación. Después, el cálculo manual se verifica con `scikit-learn` y se amplía con un experimento sobre el conjunto Iris, separando entrenamiento, validación y prueba.

El informe sigue el orden del enunciado. Todas las cifras provienen de la ejecución del cuaderno `taller_arboles_decision.ipynb`, que acompaña este documento y que carga Iris directamente desde `scikit-learn`. Las tablas y figuras indican siempre si el resultado corresponde a entrenamiento, validación o prueba. Los subtítulos llevan entre paréntesis el punto del enunciado que resuelven (por ejemplo, 2b es el punto 2, inciso b).

2 Formulación del problema

2.1 (1a) Elementos del problema

La tabla sintética describe diamantes con dos medidas y una clase. La Tabla 1 la reproduce tal como se entregó en el taller.

ID	Quilates	Profundidad (%)	Clase
1	0,30	60	A
2	0,40	61	A
3	0,50	64	A
4	0,60	62	E
5	0,70	65	A
6	0,80	63	E
7	0,90	61	E
8	1,00	64	A
9	1,10	62	E
10	1,20	65	A
11	1,30	60	E
12	1,40	63	E

Tabla 1: Tabla sintética del taller (12 diamantes). El *ID* es un identificador y no se usa como predictor.

- **Unidad de observación:** un diamante, es decir, una fila de la tabla.
- **Características X:** los quilates y la profundidad (%). Ambas son numéricas y se conocen antes de emitir la clasificación.

- **Etiqueta y:** la clase del corte.
- **Clases posibles:** aceptable (A) y excelente (E). Por eso el problema es de clasificación binaria.

Es aprendizaje supervisado porque cada ejemplo trae la respuesta correcta, la clase, y el modelo aprende a partir de ella. Es de clasificación porque la salida es una categoría y no un número continuo.

2.2 (1b) Vocabulario del árbol en este caso

- **Raíz:** la primera pregunta, que recibe los 12 diamantes. En este caso es *profundidad* $\leq$ *63,5*.
- **Nodo interno:** una pregunta que recibe solo una parte de los casos. Aquí es *quilates* $\leq$ *0,50*, que recibe los 8 diamantes con profundidad menor o igual a 63,5.
- **Rama:** cada respuesta posible a una pregunta, sí ($\leq$) o no ($>$), que conduce al siguiente nodo.
- **Hoja:** un nodo final que ya no pregunta y asigna una clase. El árbol construido tiene tres hojas.

2.3 (1c) Campo posterior a la clasificación y disponibilidad del precio

Un compañero propone incluir el campo *resultado final de la inspección*, que se registra después de asignar la clase. Ese campo no debe utilizarse. El problema es la **fuga de información**: la variable solo existe cuando la clase ya fue decidida, de modo que probablemente refleja o hereda esa decisión. El modelo podría parecer muy preciso en los datos históricos, pero en el momento de predecir el campo todavía no existe. El enunciado pide predecir con características disponibles antes de emitir la clasificación, y este campo incumple esa condición.

Si se incorpora el precio, debe cumplirse que su valor esté disponible **antes** de asignar la clase, con el mismo significado y la misma forma de cálculo en entrenamiento y en uso real. Además, el precio no puede depender de la clasificación del corte. Si se fija después de saber si el corte es excelente, entra en el mismo problema de fuga que el campo anterior.

3 Selección de la raíz con el índice Gini

3.1 Fórmulas y convenciones

Para un nodo S con K clases, p_k es la proporción de la clase k en el nodo. Una pregunta divide el nodo en un hijo izquierdo S_L y un hijo derecho S_R:

$$G(S) = 1 - \sum_{k=1}^{K} p_k^2, \qquad G_{div} = \frac{|S_L|}{|S|} G(S_L) + \frac{|S_R|}{|S|} G(S_R), \qquad \Delta G = G(S) - G_{div}.$$

- x es el valor del predictor por el que pregunta el nodo (los quilates o la profundidad) y t es el umbral de la pregunta.
- **Izquierda:** casos con $x \leq t$. **Derecha:** casos con $x > t$.
- Se prefiere la división con mayor ΔG.

3.2 (2a) Impureza de la raíz

Los 12 diamantes tienen 6 casos A (ID 1, 2, 3, 5, 8 y 10) y 6 casos E (ID 4, 6, 7, 9, 11 y 12).

$$G(S) = 1 - \left(\tfrac{6}{12}\right)^2 - \left(\tfrac{6}{12}\right)^2 = 1 - 0{,}2500 - 0{,}2500 = 0{,}5000$$

$G(S) = 0{,}5000$**.** Es la impureza máxima para dos clases, porque están perfectamente equilibradas.

3.3 (2b) Comparación de las dos preguntas candidatas

Solo se comparan las dos preguntas pedidas. La Figura 1 muestra cómo cada una reparte los 12 casos, y la Tabla 2 lista los ID de cada hijo.

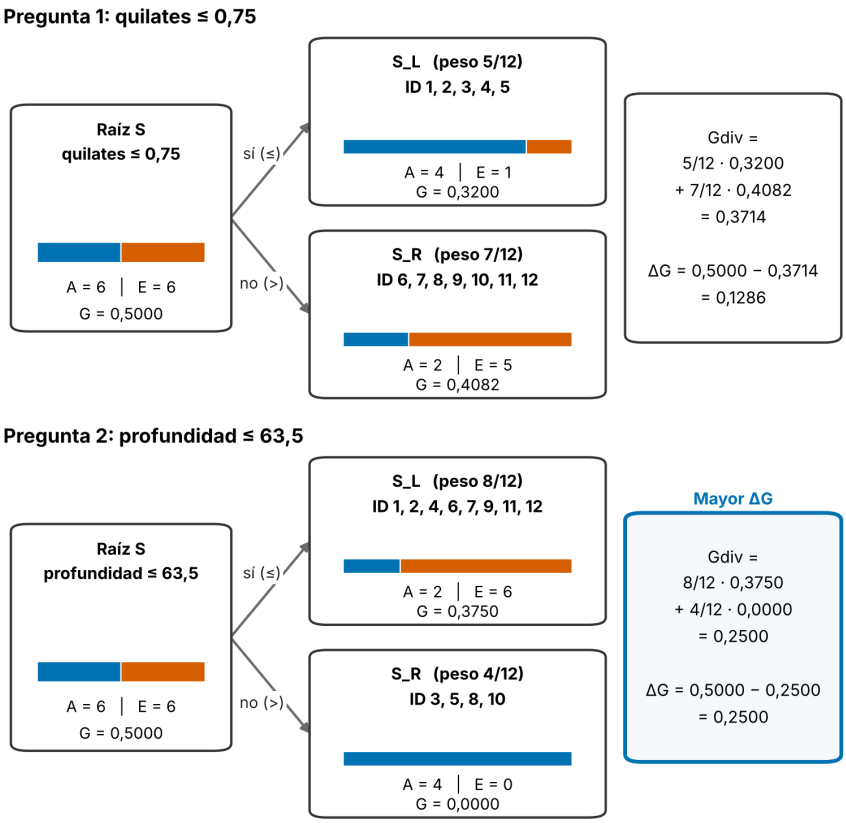


Figura 1: División de los 12 casos con cada pregunta candidata. Cada caja muestra los ID, el conteo A/E, la impureza G y el peso del hijo en la impureza ponderada.

Cómo leerla.

- **Estructura:** a la izquierda está la raíz con sus 12 casos. Las flechas llevan a los hijos, con la respuesta sí ($x \leq t$) o no ($x > t$), y la caja de la derecha resume la impureza ponderada y la reducción ΔG. La barra de cada caja es la proporción de casos A (azul) y E (naranja).
- **Qué se ve:** con quilates $\leq 0{,}75$ ambos hijos conservan casos de las dos clases. Con profundidad $\leq 63{,}5$ el hijo derecho es completamente azul, es decir, puro.
- **Por qué importa:** una barra con un solo color indica un nodo puro ($G = 0$). La pregunta con más casos puros deja menos impureza y logra mayor ΔG.

Pregunta	Hijo	ID de los casos	A	E
quilates $\leq 0{,}75$	S_L	1, 2, 3, 4, 5	4	1
	S_R	6, 7, 8, 9, 10, 11, 12	2	5
profundidad $\leq 63{,}5$	S_L	1, 2, 4, 6, 7, 9, 11, 12	2	6
	S_R	3, 5, 8, 10	4	0

Tabla 2: ID y conteo de clases de los hijos de cada pregunta candidata.

Cálculo de la pregunta 1: quilates $\leq$ 0,75

$$
\begin{aligned}
G(S_L) &= 1 - \left(\tfrac{4}{5}\right)^2 - \left(\tfrac{1}{5}\right)^2 = 1 - 0{,}6400 - 0{,}0400 = 0{,}3200 \\
G(S_R) &= 1 - \left(\tfrac{2}{7}\right)^2 - \left(\tfrac{5}{7}\right)^2 = \tfrac{20}{49} = 0{,}4082 \\
G_{div} &= \tfrac{5}{12}(0{,}3200) + \tfrac{7}{12}(0{,}4082) = 0{,}1333 + 0{,}2381 = 0{,}3714 \\
\Delta G &= 0{,}5000 - 0{,}3714 = 0{,}1286
\end{aligned}
$$

Cálculo de la pregunta 2: profundidad $\leq$ 63,5

$$
\begin{aligned}
G(S_L) &= 1 - \left(\tfrac{2}{8}\right)^2 - \left(\tfrac{6}{8}\right)^2 = 1 - 0{,}0625 - 0{,}5625 = 0{,}3750 \\
G(S_R) &= 1 - \left(\tfrac{4}{4}\right)^2 - \left(\tfrac{0}{4}\right)^2 = 0{,}0000 \\
G_{div} &= \tfrac{8}{12}(0{,}3750) + \tfrac{4}{12}(0{,}0000) = 0{,}2500 + 0{,}0000 = 0{,}2500 \\
\Delta G &= 0{,}5000 - 0{,}2500 = 0{,}2500
\end{aligned}
$$

Pregunta	n_L	**A/E en** S_L	$G(S_L)$	n_R	**A/E en** S_R	$G(S_R)$	G_{div}	ΔG
quilates $\leq$ 0,75	5	4 / 1	0,3200	7	2 / 5	0,4082	0,3714	0,1286
profundidad $\leq$ 63,5	8	2 / 6	0,3750	4	4 / 0	0,0000	0,2500	0,2500

Tabla 3: Tabla comparativa de las dos preguntas candidatas para la raíz (12 casos de la tabla sintética, cuatro decimales). A/E indica el número de casos de cada clase.

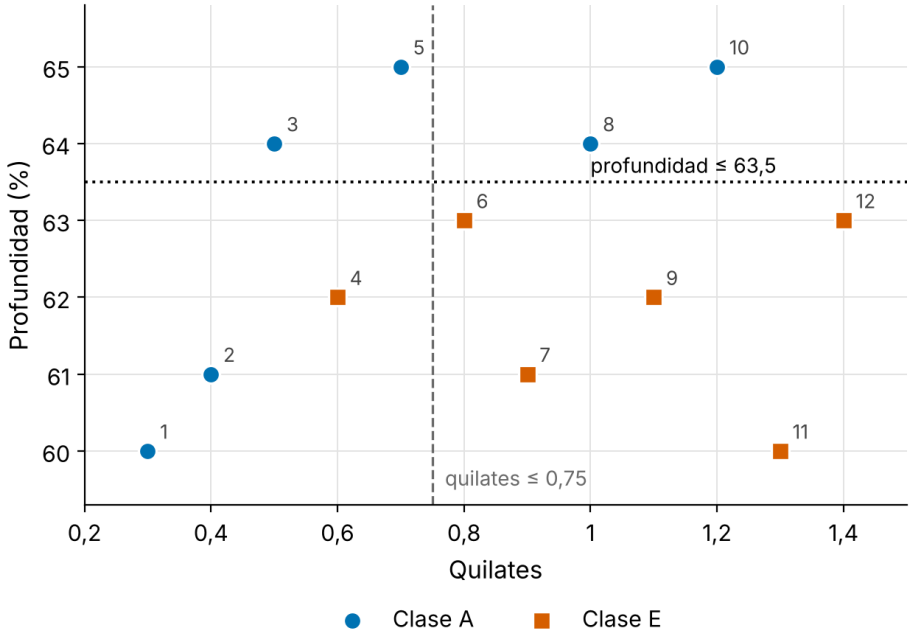


Figura 2: Diamantes de la tabla sintética en el plano quilates y profundidad, con las dos preguntas candidatas. Los números junto a cada punto son el ID.

Cómo leerla.

- **Estructura:** el eje horizontal son los quilates, el vertical la profundidad (%), los círculos azules son la clase A y los cuadrados naranjas la clase E.
- **Qué se ve:** la línea punteada negra, profundidad $\leq 63{,}5$, deja arriba solo puntos azules (ID 3, 5, 8 y 10). La línea discontinua gris, quilates $\leq 0{,}75$, deja puntos de ambas clases a los dos lados.
- **Por qué importa:** una buena pregunta separa las clases. Se nota a simple vista que la línea horizontal deja un lado completamente puro y la vertical no.

3.4 (2c) Elección de la raíz

Raíz elegida: profundidad $\leq$ 63,5. Su reducción de impureza es $\Delta G = 0{,}2500$, casi el doble de la de quilates $\leq 0{,}75$ ($\Delta G = 0{,}1286$), y uno de sus hijos queda completamente puro.

Por qué no se promedian las impurezas sin pesar los tamaños. Un hijo con pocos casos pesa menos en la decisión que uno con muchos.

- En profundidad $\leq 63{,}5$, el hijo derecho tiene 4 de los 12 casos y el izquierdo tiene 8.
- Un promedio simple, $(0{,}3750 + 0{,}0000)/2 = 0{,}1875$, daría la misma importancia a un grupo de 4 casos que a uno de 8 y subestimaría la impureza que realmente queda. Con la ponderación se obtiene 0,2500.
- La diferencia sería aún mayor si una pregunta aislara un solo caso: el promedio simple la haría parecer excelente aunque casi todos los casos siguieran mezclados en el otro hijo.

Alcance de la comparación. Comparar solo dos preguntas no demuestra que la elegida sea óptima entre todos los umbrales posibles: otras preguntas que no se evaluaron aquí podrían separar mejor los casos.

4 Construcción e interpretación del árbol

4.1 (3a) División adicional del hijo impuro

- **Hijo derecho (profundidad $>$ 63,5):** ID 3, 5, 8 y 10, con 4 casos A y ninguno E. Es puro, así que se convierte en hoja.
- **Hijo izquierdo (profundidad $\leq$ 63,5):** ID 1, 2, 4, 6, 7, 9, 11 y 12, con 2 casos A y 6 casos E, y $G = 0{,}3750$. Es impuro, y es el único que se sigue dividiendo.

Para cada predictor se ordenan los valores distintos del nodo y se toman los puntos medios entre valores consecutivos como umbrales candidatos.

Predictor	**Valores ordenados**	**Puntos medios (umbrales)**
Quilates	0,30; 0,40; 0,60; 0,80; 0,90; 1,10; 1,30; 1,40	0,35; 0,50; 0,70; 0,85; 1,00; 1,20; 1,35
Profundidad	60; 61; 62; 63	60,5; 61,5; 62,5

Tabla 4: Valores ordenados y umbrales candidatos del hijo izquierdo (8 casos).

La Tabla 5 evalúa los diez umbrales, con ΔG medido respecto del nodo de 8 casos ($G = 0{,}3750$).

Pregunta	n_L	**A/E en** S_L	$G(S_L)$	n_R	**A/E en** S_R	$G(S_R)$	G_{div}	ΔG
quilates $\leq$ 0,35	1	1 / 0	0,0000	7	1 / 6	0,2449	0,2143	0,1607
quilates $\leq$ 0,50	2	2 / 0	0,0000	6	0 / 6	0,0000	0,0000	0,3750
quilates $\leq$ 0,70	3	2 / 1	0,4444	5	0 / 5	0,0000	0,1667	0,2083
quilates $\leq$ 0,85	4	2 / 2	0,5000	4	0 / 4	0,0000	0,2500	0,1250
quilates $\leq$ 1,00	5	2 / 3	0,4800	3	0 / 3	0,0000	0,3000	0,0750
quilates $\leq$ 1,20	6	2 / 4	0,4444	2	0 / 2	0,0000	0,3333	0,0417
quilates $\leq$ 1,35	7	2 / 5	0,4082	1	0 / 1	0,0000	0,3571	0,0179
profundidad $\leq$ 60,5	2	1 / 1	0,5000	6	1 / 5	0,2778	0,3333	0,0417
profundidad $\leq$ 61,5	4	2 / 2	0,5000	4	0 / 4	0,0000	0,2500	0,1250
profundidad $\leq$ 62,5	6	2 / 4	0,4444	2	0 / 2	0,0000	0,3333	0,0417

Tabla 5: Divisiones candidatas del hijo izquierdo (8 casos, $G = 0{,}3750$). La reducción ΔG se mide respecto de ese nodo.

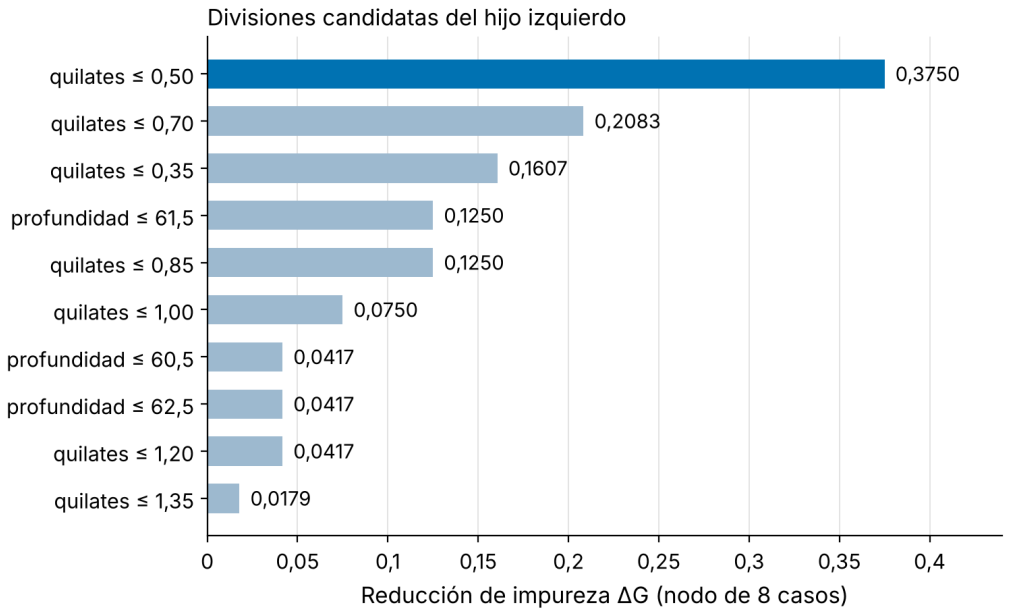


Figura 3: Reducción de impureza ΔG de los diez umbrales candidatos del hijo izquierdo, ordenados de menor a mayor.

Cómo leerla.

- **Estructura:** cada barra es un umbral candidato y su longitud es la reducción de impureza ΔG. La barra azul oscura es la mejor.
- **Qué se ve:** quilates $\leq 0{,}50$ alcanza 0,3750, que es todo lo que se puede reducir en ese nodo, porque la impureza del nodo es 0,3750. La siguiente, quilates $\leq 0{,}70$, llega a 0,2083.
- **Por qué importa:** una reducción igual a la impureza del nodo significa que los dos hijos quedan puros y que no hace falta dividir más.

Cálculo de la mejor división: quilates $\leq$ 0,50 (punto medio entre 0,40 y 0,60).

$$
\begin{aligned}
S_L &= \{\text{ID } 1,2\} : A = 2,\ E = 0 && \Rightarrow\ G(S_L) = 1 - 1^2 - 0^2 = 0{,}0000 \\
S_R &= \{\text{ID } 4,6,7,9,11,12\} : A = 0,\ E = 6 && \Rightarrow\ G(S_R) = 1 - 0^2 - 1^2 = 0{,}0000 \\
G_{div} &= \tfrac{2}{8}(0{,}0000) + \tfrac{6}{8}(0{,}0000) = 0{,}0000 \\
\Delta G &= 0{,}3750 - 0{,}0000 = 0{,}3750
\end{aligned}
$$

Segunda pregunta: quilates $\leq$ 0,50. Ambos hijos quedan puros, así que el árbol se detiene y su profundidad máxima es 2.

4.2 (3b) Árbol resultante

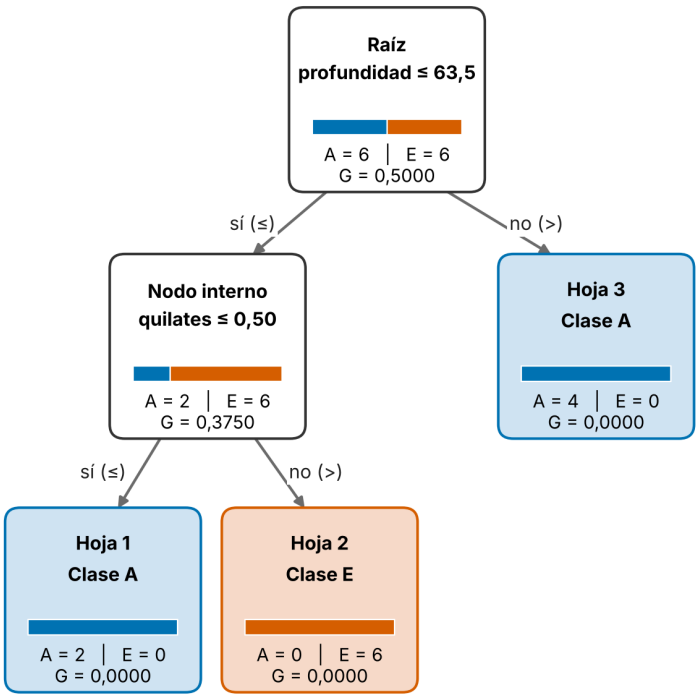


Figura 4: Árbol manual construido con el índice Gini sobre los 12 casos de la tabla sintética.

Cómo leerla.

- **Estructura:** cada caja es un nodo con su pregunta, la barra de proporción A (azul) y E (naranja), el conteo y la impureza G. Las flechas llevan la respuesta sí ($\leq$) o no ($>$). Las cajas de color son hojas y su clase está indicada.
- **Qué se ve:** la raíz envía 4 casos A a la hoja 3 y 8 casos al nodo de quilates, que los separa por completo: 2 A en la hoja 1 y 6 E en la hoja 2.
- **Por qué importa:** muestra que el árbol tiene profundidad 2 y que todas las hojas son puras, por lo que no hubo empates que resolver con la convención de asignar A.

La Figura 5 muestra el mismo árbol dibujado a mano, y la Figura 4 es su versión digital.

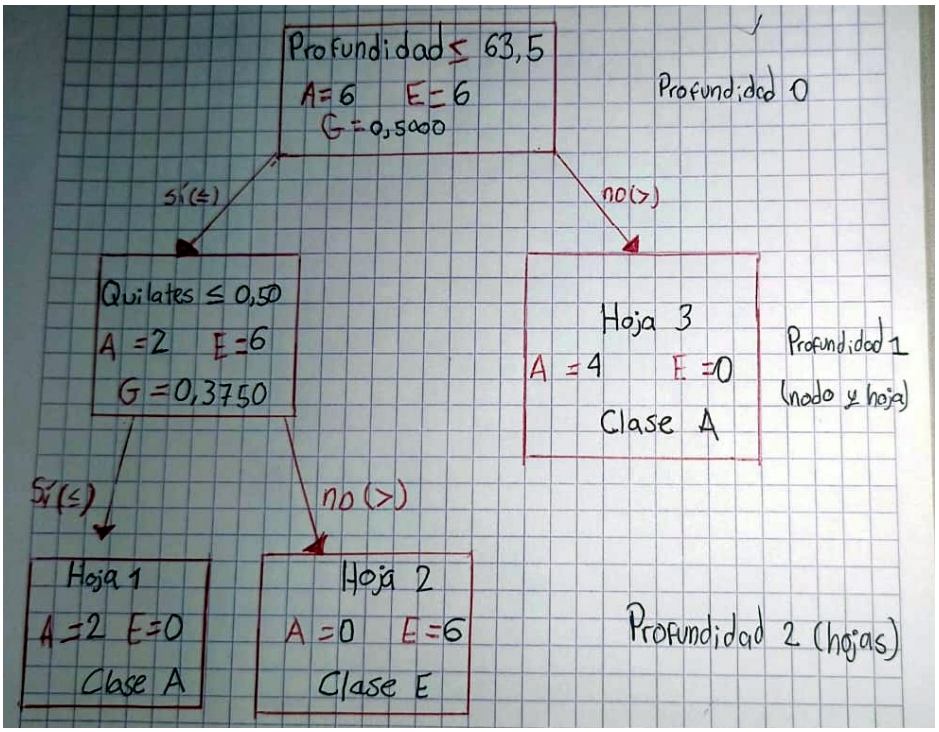


Figura 5: Árbol de decisión dibujado a mano, con las preguntas, las ramas, el conteo A/E y la clase de cada hoja. Foto del trabajo del autor.

Cómo leerla.

- **Estructura:** la raíz está arriba y cada flecha lleva su respuesta, sí ($\leq$) a la izquierda y no ($>$) a la derecha. Cada caja tiene la pregunta o el nombre de la hoja, el conteo A/E y, en los nodos, la impureza G. A la derecha se rotula la profundidad de cada nivel.
- **Qué se ve:** la raíz *profundidad* $\leq$ *63,5* (A = 6, E = 6) envía 4 casos A a la hoja 3 y 8 casos al nodo *quilates* $\leq$ *0,50*, que a su vez termina en la hoja 1 (clase A) y la hoja 2 (clase E).
- **Por qué importa:** cumple lo que pide el punto 3b: máximo dos divisiones por camino, preguntas y ramas rotuladas, conteo A/E y clase en cada hoja, y se detiene en la hoja 3 porque el nodo ya es puro.

4.3 (3c) Reglas por hoja

Hoja	Regla	A / E	Clase
1	SI profundidad $\leq$ 63,5 Y quilates $\leq$ 0,50, ENTONCES clase A	2 / 0	A
2	SI profundidad $\leq$ 63,5 Y quilates $>$ 0,50, ENTONCES clase E	0 / 6	E
3	SI profundidad $>$ 63,5, ENTONCES clase A	4 / 0	A

Tabla 6: Regla SI … ENTONCES por hoja, con el número de casos de ajuste de cada clase.

4.4 (3c) Clasificación de los casos nuevos

Caso	Quilates	Profundidad (%)	Recorrido	Hoja	Clase
N1	0,45	62	profundidad $\leq$ 63,5 (sí) $\rightarrow$ quilates $\leq$ 0,50 (sí)	H1	A
N2	1,15	64	profundidad $\leq$ 63,5 (no)	H3	A
N3	0,85	61	profundidad $\leq$ 63,5 (sí) $\rightarrow$ quilates $\leq$ 0,50 (no)	H2	E
N4	0,55	63,5	profundidad $\leq$ 63,5 (sí) $\rightarrow$ quilates $\leq$ 0,50 (no)	H2	E

Tabla 7: Clasificación manual de los casos nuevos N1 a N4 con el recorrido seguido en el árbol.

Dos casos merecen una nota. N4 tiene profundidad exactamente 63,5, que cumple la condición $\leq$ y por eso sigue la rama izquierda. N2 tiene profundidad 64, mayor que 63,5, y termina directamente en la hoja 3.

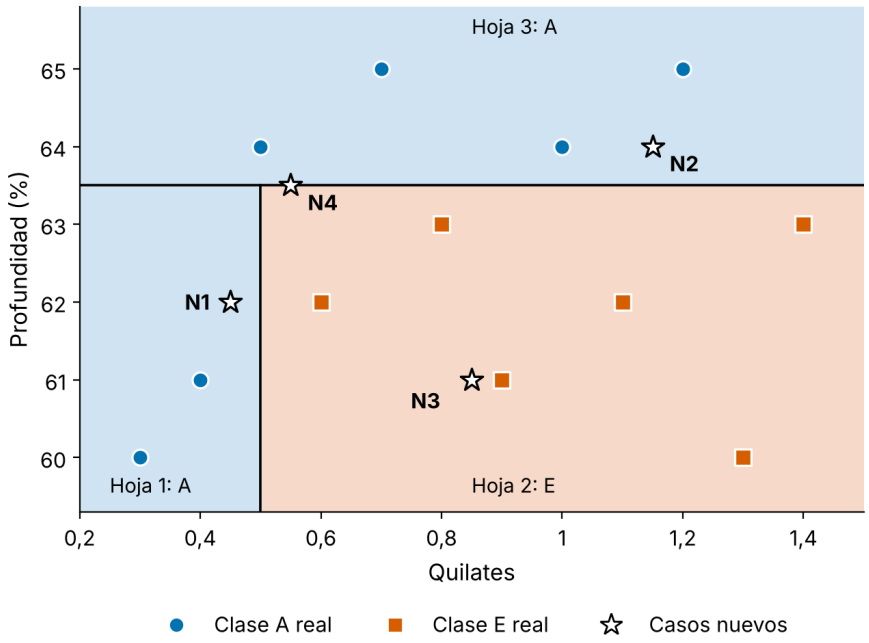


Figura 6: Mapa de decisión del árbol manual sobre el plano quilates y profundidad, con los 12 casos de ajuste y los casos nuevos N1 a N4.

Cómo leerla.

- **Estructura:** el plano se divide en tres regiones rectangulares, una por hoja. La región azul clara predice A y la naranja clara predice E. Las estrellas son los casos sin etiqueta.
- **Qué se ve:** N1 cae en la hoja 1 (A), N2 en la hoja 3 (A), y N3 y N4 en la hoja 2 (E). N4 está justo sobre la frontera horizontal.
- **Por qué importa:** permite ver que cada regla del árbol corresponde a un rectángulo y que los casos cercanos a una frontera, como N4, son los más sensibles a un cambio de umbral.

4.5 Discusión sobre los casos nuevos y la exactitud en los datos de ajuste

Los casos N1 a N4 no tienen etiqueta real, por lo que **no se puede afirmar que el árbol acertó**. Solo se puede decir qué clase predice. Comprobar un acierto exige conocer la clase verdadera de esos diamantes.

Una exactitud del 100 % sobre las 12 filas usadas para construir el árbol demuestra que el árbol logró representar esos datos: las reglas encontradas separan correctamente todos los ejemplos de ajuste, lo cual era esperable porque las tres hojas son puras. No demuestra que el modelo clasifique bien diamantes nuevos. Con 12 filas, parte de lo aprendido puede ser una coincidencia de esa muestra, por ejemplo que el umbral 0,50 caiga justo entre los valores 0,40 y 0,60. Para medir la generalización hacen falta datos que no participaron en el ajuste.

5 Evaluación de las predicciones

Un clasificador se evaluó en un conjunto independiente de 20 casos. La matriz de confusión es un resultado hipotético del enunciado y no se deriva del árbol anterior. Con A como clase positiva, los cuatro tipos de resultado son:

	Predicho A	**Predicho E**
Real A	6 (VP)	2 (FN)
Real E	3 (FP)	9 (VN)

Tabla 8: Matriz de confusión hipotética de 20 casos, con A como clase positiva.

Por lo tanto $VP = 6$, $FN = 2$, $FP = 3$ y $VN = 9$, con $N = 20$.

5.1 (4a) Métricas e interpretación

- **Exactitud:** $\frac{VP+VN}{N} = \frac{6+9}{20} = 0{,}7500$. El clasificador acierta 15 de los 20 casos, es decir, el 75 %.
- **Precisión:** $\frac{VP}{VP+FP} = \frac{6}{6+3} = 0{,}6667$. Cuando el modelo dice A, acierta 2 de cada 3 veces.
- **Exhaustividad (recall):** $\frac{VP}{VP+FN} = \frac{6}{6+2} = 0{,}7500$. De los 8 diamantes que son realmente A, el modelo encuentra 6.
- **F1:** $\frac{2VP}{2VP+FP+FN} = \frac{2\cdot 6}{2\cdot 6+3+2} = \frac{12}{17} = 0{,}7059$. Resume precisión y recall en un solo número y queda cerca del más bajo de los dos.

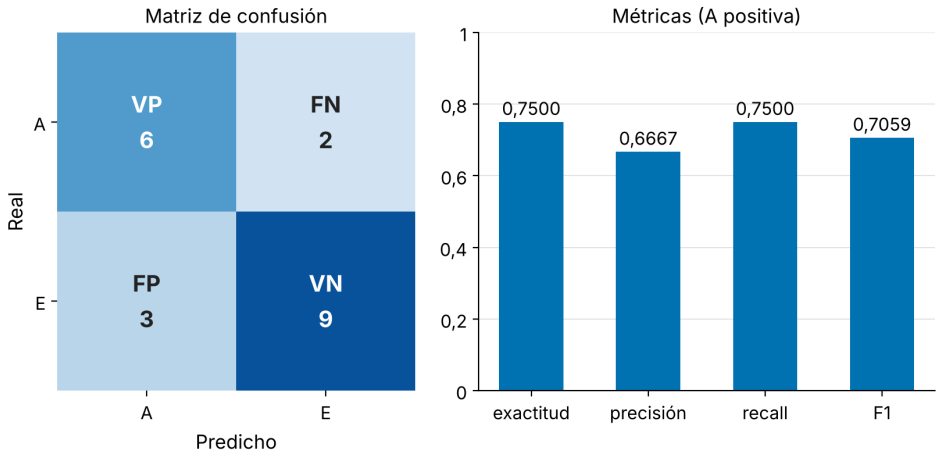


Figura 7: Matriz de confusión hipotética (izquierda) y métricas con A como clase positiva (derecha), sobre los 20 casos del enunciado.

Cómo leerla.

- **Estructura:** a la izquierda, las filas son la clase real y las columnas la predicha, con el conteo en cada celda. A la derecha, una barra por métrica.
- **Qué se ve:** la diagonal (6 y 9) concentra los aciertos. Las celdas fuera de la diagonal son los 5 errores: 2 FN y 3 FP. La precisión (0,6667) es la métrica más baja, porque hay más FP que FN.
- **Por qué importa:** muestra que el modelo se equivoca más al llamar A a diamantes que son E que al dejar pasar diamantes A.

5.2 (4b) Significado de los dos errores

- **Clasificar un diamante excelente como aceptable** es el caso real E y predicho A, un falso positivo, porque A es la clase positiva. Hay 3 en la matriz. El diamante se subvalora.

- **El error inverso** es clasificar un diamante aceptable como excelente: real A y predicho E, un falso negativo. Hay 2 en la matriz. El diamante se sobrevalora.

El costo depende del uso. Si un comerciante usa el modelo para fijar el precio de diamantes que recibe en consignación, subvalorar un diamante excelente significa pagar o vender por menos de lo que vale, y ese error resulta más costoso. En cambio, si el laboratorio emite certificados de calidad, sobrevalorar un diamante aceptable es más grave: el comprador paga de más, puede reclamar y la certificación pierde credibilidad.

5.3 (4c) Modelo que siempre predice la clase mayoritaria

En un conjunto con 95 ejemplos A y 5 ejemplos E, un modelo que siempre predice A tiene $VP = 95$, $FN = 0$, $FP = 5$ y $VN = 0$.

- **Exactitud:** $\dfrac{95+0}{100} = 0{,}95$.
- **Recall de E:** $\dfrac{VN}{VN+FP} = \dfrac{0}{0+5} = 0{,}00$, porque ningún diamante excelente se detecta.

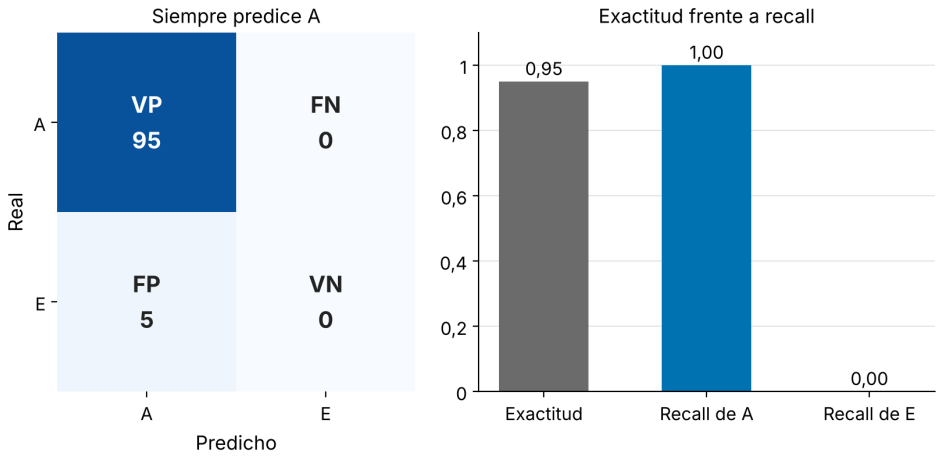


Figura 8: Modelo que siempre predice A sobre un conjunto de 95 ejemplos A y 5 ejemplos E: matriz de confusión (izquierda) y comparación entre exactitud y recall por clase (derecha).

Cómo leerla.

- **Estructura:** la matriz de la izquierda solo tiene datos en la columna de *Predicho A*. Las barras de la derecha comparan la exactitud con el recall de cada clase.
- **Qué se ve:** la exactitud llega a 0,95 y el recall de A a 1,00, pero el recall de E es 0,00.
- **Por qué importa:** una exactitud alta puede ocultar que una clase minoritaria nunca se detecta. Por eso hay que revisar las métricas por clase y no solo la exactitud global.

6 Implementación y generalización en Python

6.1 Parte A (5A): verificación del cálculo manual

Las 12 filas se transcribieron a un `DataFrame` y se entrenó un `DecisionTreeClassifier(criterion="gini", max_depth=2, random_state=42)` con los dos predictores. El árbol resultante tiene profundidad 2 y tres hojas.

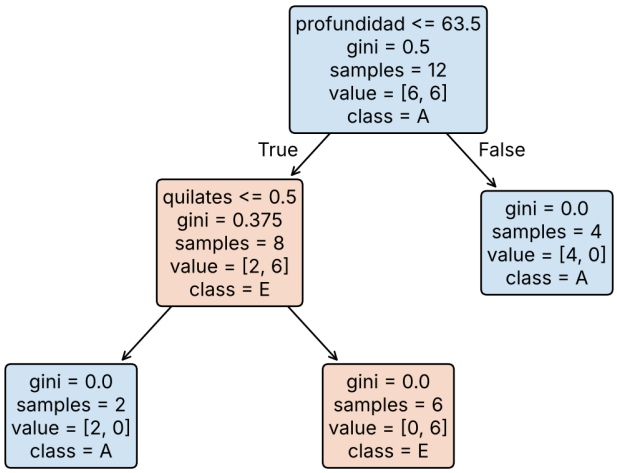


Figura 9: Árbol entrenado con `scikit-learn` sobre los 12 casos sintéticos, dibujado con `plot_tree`. Los textos *gini*, *samples*, *value* y *class* son los rótulos que genera la librería.

Cómo leerla.

- **Estructura:** cada recuadro muestra la pregunta, la impureza (*gini*), el número de casos (*samples*), el conteo por clase (*value*, en el orden A, E) y la clase asignada. *True* lleva a los casos que cumplen la pregunta.
- **Qué se ve:** la raíz es *profundidad* $\leq$ *63,5* y su hijo izquierdo es *quilates* $\leq$ *0,5*. Las tres hojas son puras: [2, 0], [0, 6] y [4, 0].
- **Por qué importa:** coincide con la construcción manual de la Figura 4, con los mismos umbrales y las mismas hojas. Como las impurezas coinciden, no fue necesario explicar diferencias por empates o por umbrales adicionales.

Las predicciones de N1 a N4 también coinciden con las manuales:

Caso	Predicción manual	Predicción de `scikit-learn`	Coincide
N1	A	A	sí
N2	A	A	sí
N3	E	E	sí
N4	E	E	sí

Tabla 9: Predicciones de los casos nuevos con el árbol manual y con `scikit-learn`.

La exactitud del árbol sobre las 12 filas de ajuste es 1,00, pero no debe interpretarse como evidencia de generalización, porque esas mismas filas se usaron para construirlo.

6.2 Parte B (5B): experimento con Iris

En esta parte el problema es multiclase, por lo que A deja de ser la clase positiva. Las métricas por clase se calculan tomando cada especie contra las demás.

6.2.1 (a) Datos y particiones

Iris contiene 150 flores, cuatro medidas en centímetros y tres especies con 50 flores cada una.

- **Predictores:** `sepal length (cm)` (largo del sépalo), `sepal width (cm)` (ancho del sépalo), `petal length (cm)` (largo del pétalo) y `petal width (cm)` (ancho del pétalo). Los nombres en inglés son los que entrega `iris.feature_names`, que el taller indica usar al graficar.
- **Clases:** *setosa*, *versicolor* y *virginica*.

La partición se hizo en dos pasos, como indica el código inicial: primero 20 % para prueba, y del 80 % restante, 25 % para validación, que equivale al 20 % del total. Quedan 90 flores para entrenamiento, 30 para validación y 30 para prueba.

- **Por qué estratificar:** mantiene la misma proporción de cada especie en las tres particiones. Sin estratificar, una partición pequeña podría quedar con muy pocas flores de una especie y su métrica sería poco confiable.
- **Por qué una semilla fija:** permite que quien ejecute el cuaderno obtenga exactamente las mismas particiones y los mismos resultados.
- **Por qué tres particiones:** el entrenamiento ajusta los árboles, la validación sirve para elegir entre ellos y la prueba se reserva para una única evaluación final, sin influir en la elección.

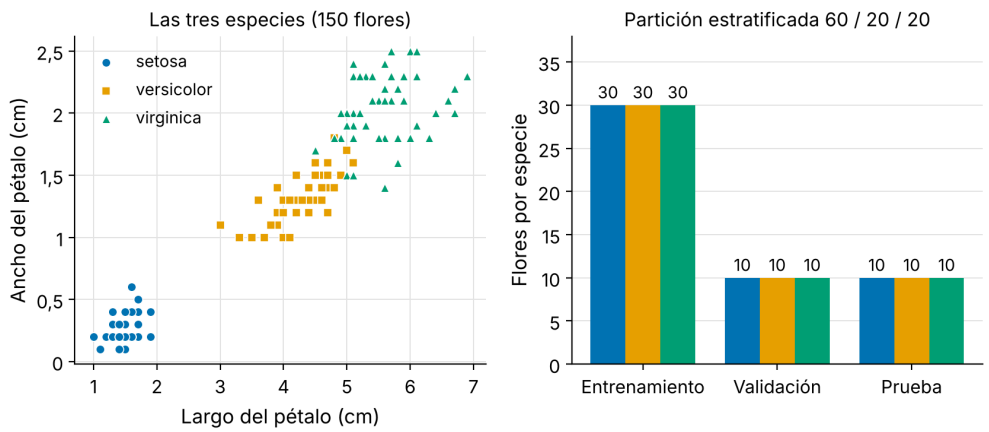


Figura 10: Las 150 flores de Iris según largo y ancho del pétalo (izquierda) y número de flores por especie en cada partición (derecha).

Cómo leerla.

- **Estructura:** a la izquierda, cada punto es una flor y la forma y el color indican la especie. A la derecha, un grupo de barras por partición con una barra por especie.
- **Qué se ve:** setosa queda aislada en la esquina inferior izquierda, mientras versicolor y virginica se acercan y se mezclan un poco. Las barras de cada partición tienen la misma altura: 30, 10 y 10 flores por especie.
- **Por qué importa:** anticipa que separar setosa es fácil y que el reto está entre versicolor y virginica, y confirma que la estratificación funcionó.

6.2.2 (b) y (c) Tres candidatos y selección con validación

Se entrenaron, solo con las 90 flores de entrenamiento, tres árboles con `criterion="gini"`, semilla 42 y profundidades máximas 1, 3 y sin límite. La prueba no se usó para ajustar ni para elegir.

Profundidad máxima	Exactitud entrenamiento	Exactitud validación	F1 macro validación	Profundidad efectiva	Hojas
1	0,6667	0,6667	0,5556	1	2
3	0,9889	0,9000	0,8997	3	4
sin límite	1,0000	0,9333	0,9333	4	5

Tabla 10: Comparación de los tres candidatos. Las exactitudes de entrenamiento y validación y el F1 macro de validación provienen de las particiones de 90 y 30 flores.

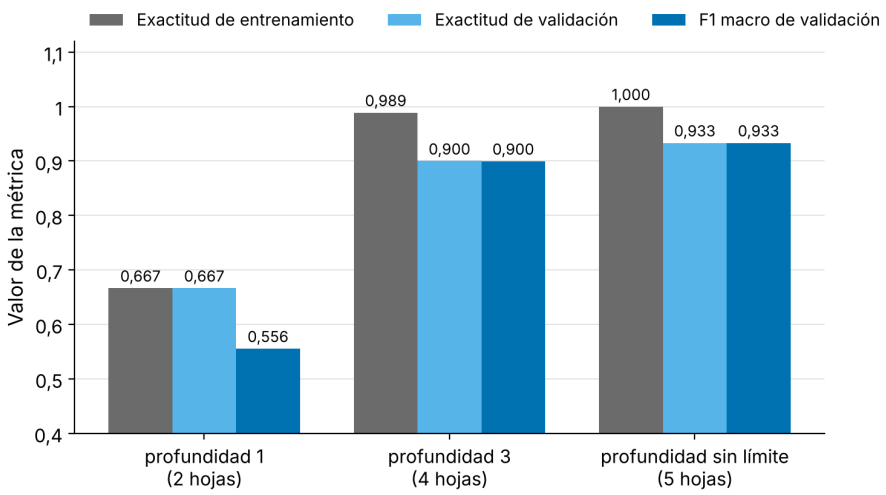


Figura 11: Exactitud de entrenamiento, exactitud de validación y F1 macro de validación de los tres candidatos.

Cómo leerla.

- **Estructura:** un grupo de tres barras por candidato: gris es entrenamiento, azul claro es validación y azul oscuro es el F1 macro de validación. Bajo cada grupo aparece el número de hojas.
- **Qué se ve:** con profundidad 1 las tres barras son bajas (0,6667, 0,6667 y 0,5556). Con profundidad 3 suben a 0,9889, 0,9000 y 0,8997. Sin límite llegan a 1,0000, 0,9333 y 0,9333.
- **Por qué importa:** permite comparar candidatos con la misma métrica de selección, el F1 macro de validación, y ver la distancia entre entrenamiento y validación.

Selección. El modelo con mayor F1 macro de validación es el árbol **sin límite de profundidad** (0,9333). No hubo empate que resolver, por lo que no fue necesario aplicar el criterio de menor profundidad y menos hojas. Su profundidad efectiva es 4 y tiene 5 hojas.

Señales de sobreajuste.

- **Profundidad 1:** el modelo es demasiado simple. Solo separa setosa del resto, y por eso su exactitud es 0,6667 tanto en entrenamiento como en validación. Es un caso de subajuste, no de sobreajuste.
- **Profundidad 3:** acierta casi todo en entrenamiento (0,9889) y baja a 0,9000 en validación, una diferencia de 0,0889.
- **Sin límite:** acierta todo el entrenamiento (1,0000) y baja a 0,9333 en validación, una diferencia de 0,0667. Es una señal moderada de ajuste a los datos de entrenamiento, aunque en validación sigue siendo el mejor.

La validación tiene solo 30 flores, así que cada caso equivale a 3,3 puntos porcentuales. La ventaja del árbol sin límite sobre el de profundidad 3 es de un solo caso (28 aciertos

frente a 27), por lo que la selección es válida según la regla del taller pero no es una diferencia amplia.

6.2.3 (d) y (e) Evaluación única en prueba y comparación con la referencia

El modelo seleccionado se evaluó una sola vez sobre las 30 flores de prueba, sin reentrenarlo.

Especie	Precisión	Recall	F1	Soporte
setosa	1,0000	1,0000	1,0000	10
versicolor	0,9000	0,9000	0,9000	10
virginica	0,9000	0,9000	0,9000	10
F1 macro			0,9333	30

Tabla 11: Métricas por especie en prueba (30 flores) del árbol sin límite de profundidad. La fila final es el F1 macro, promedio simple de los tres F1.

- **Matriz de confusión:** setosa se clasifica sin errores (10 de 10). En versicolor y virginica hay un error en cada una: una versicolor se predijo como virginica y una virginica como versicolor.
- **Exactitud y F1 macro:** ambas son 0,9333, porque hay 28 aciertos en 30 flores y las tres especies tienen el mismo número de casos.

La referencia que siempre predice la clase mayoritaria de entrenamiento se construyó con `DummyClassifier(strategy="most_frequent")`. Como las tres especies tienen 30 flores en entrenamiento, hay un empate y la librería elige una sola especie, que es la primera clase.

Modelo	Exactitud en prueba	F1 macro en prueba
Árbol seleccionado	0,9333	0,9333
Referencia (clase mayoritaria)	0,3333	0,1667

Tabla 12: Árbol seleccionado y referencia de clase mayoritaria, evaluados en prueba (30 flores).

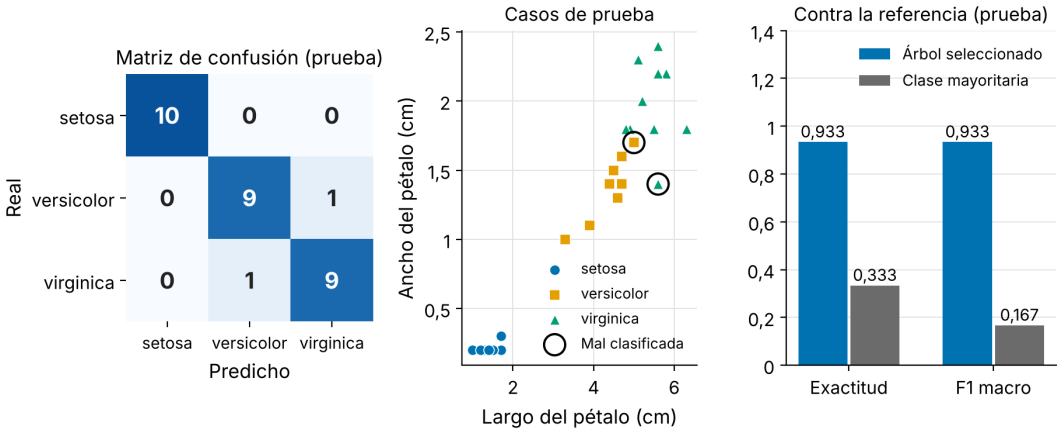


Figura 12: Evaluación en prueba del árbol seleccionado: matriz de confusión (izquierda), flores de prueba con los errores marcados (centro) y comparación con la referencia (derecha).

Cómo leerla.

- **Estructura:** la matriz tiene las especies reales en las filas y las predichas en las columnas. En el gráfico central, el color y la forma indican la especie real y los círculos negros rodean las flores mal clasificadas. A la derecha, las barras comparan el árbol con la referencia.
- **Qué se ve:** la diagonal suma 28 aciertos. Los dos errores están en la zona donde versicolor y virginica se acercan. El árbol alcanza 0,9333 en exactitud y en F1 macro, frente a 0,3333 y 0,1667 de la referencia.
- **Por qué importa:** la referencia marca el piso: predecir una sola especie da 0,3333 de exactitud, así que el árbol aporta información real. El F1 macro de la referencia es aún más bajo (0,1667), porque penaliza que dos especies no se detecten nunca.

6.2.4 (f) Árbol seleccionado y dos caminos

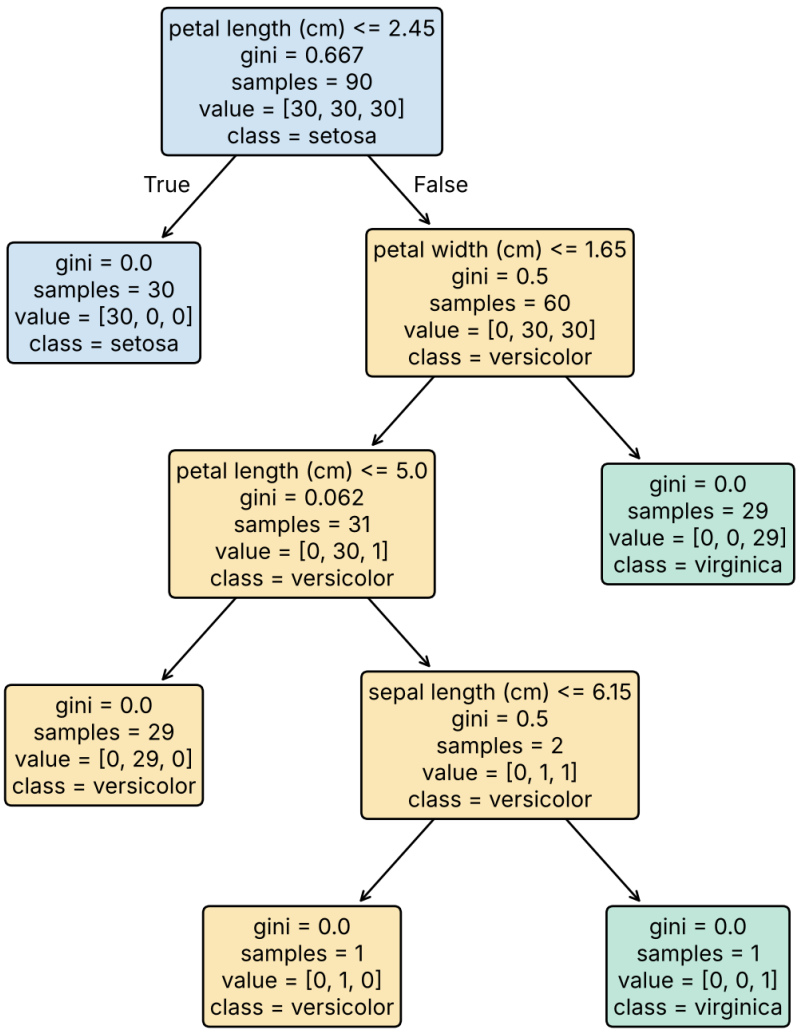


Figura 13: Árbol sin límite de profundidad entrenado con las 90 flores de entrenamiento. Los rótulos en inglés provienen de `iris.feature_names`.

Cómo leerla.

- **Estructura:** cada recuadro tiene la pregunta, *gini*, el número de flores (*samples*) y el conteo por especie (*value*, en el orden setosa, versicolor, virginica). El color indica la especie dominante.
- **Qué se ve:** el árbol usa tres de los cuatro predictores: largo y ancho del pétalo, y una sola vez el largo del sépalo. El ancho del sépalo no aparece. Casi toda la reducción de impureza viene de las dos medidas del pétalo.
- **Por qué importa:** permite seguir una predicción como una secuencia de preguntas, y revela que la última división se apoya en un nodo de solo 2 flores.

- **Camino 1 (setosa):** *largo del pétalo* $\leq$ *2,45* es verdadero, y la flor llega a una hoja pura con 30 flores de setosa. Es la separación más clara del conjunto.
- **Camino 2 (versicolor):** *largo del pétalo* $>$ *2,45*, luego *ancho del pétalo* $\leq$ *1,65*, luego *largo del pétalo* $\leq$ *5,0*. La flor llega a una hoja con 29 flores de versicolor.

La división final por el largo del sépalo ($\leq$ 6,15) se apoya en solo dos flores de entrenamiento. Ese tipo de regla es frecuente en árboles sin límite de profundidad y es donde suele aparecer el sobreajuste.

Qué permite y qué limita este experimento. Permite comparar candidatos con datos que no se usaron para ajustar, elegir con la validación y reportar una evaluación independiente que supera claramente a la referencia. Limita la conclusión que la prueba tiene solo 30 flores, de modo que un error cambia la exactitud en 3,3 puntos porcentuales y no se puede afirmar que 0,9333 sea el desempeño verdadero del modelo. Además, Iris es un conjunto pequeño y limpio, así que el resultado no anticipa el desempeño con datos reales más ruidosos. La selección no se modificó después de observar la prueba.

7 Conclusiones

- **Formulación:** el problema es de clasificación supervisada con dos predictores y dos clases. El campo posterior a la clasificación debe excluirse por fuga de información, y el precio solo puede incluirse si está disponible antes de emitir la clase.
- **Raíz:** entre las dos preguntas comparadas, *profundidad* $\leq$ *63,5* reduce la impureza en 0,2500 y *quilates* $\leq$ *0,75* en 0,1286. La ponderación por tamaño de los hijos es lo que hace comparables las dos divisiones.
- **Árbol manual:** con una segunda pregunta, *quilates* $\leq$ *0,50*, las tres hojas quedan puras y el árbol clasifica bien las 12 filas de ajuste. Eso no basta para afirmar que generalice, y los casos N1 a N4 no pueden calificarse como aciertos porque no tienen etiqueta real.
- **Métricas:** en la matriz hipotética, la exactitud es 0,7500, la precisión 0,6667, el recall 0,7500 y el F1 0,7059. El modelo que siempre predice A llega a 0,95 de exactitud con recall de E igual a 0,00, por lo que las métricas por clase son necesarias.
- **Verificación:** `scikit-learn` reproduce la raíz, los umbrales, las hojas y las predicciones de N1 a N4 de la construcción manual.
- **Iris:** el árbol sin límite de profundidad obtuvo el mayor F1 macro de validación (0,9333) y en prueba alcanzó 0,9333 de exactitud y de F1 macro, frente a 0,3333 y 0,1667 de la referencia. Los dos errores están entre versicolor y virginica.
- **Alcance:** la validación y la prueba tienen 30 flores cada una, por lo que las diferencias de un solo caso pesan 3,3 puntos porcentuales. El experimento permite comparar y seleccionar con orden, pero no prueba un desempeño definitivo.